

OPTIMISATION DE MODELES NEURONAUX A OSCILLATEURS COUPLÉS - LIVRABLE 1

DA SILVA Tristan - BATTAGLIA Charles-Antoine
BOTTÉ-MAGALHAES Jules - GAUTHIER Keanu - FRAYSSE Ianis

JUNIA - ISEN - AP4

<https://github.com/KeanuGauthier/Socle-Modele-Neuronaux-RD.git>

Table des matières

1	Reformulation du sujet	2
1.1	Ce que demande le sujet	2
1.2	La carte conceptuelle	3
1.3	Lecture du schéma	4
1.3.1	Le noyau : ce que l'on étudie	4
1.3.2	Les quatre dimensions	4
1.3.3	L'anneau : une démarche itérative, pas linéaire	4
1.4	Ce que le schéma met en évidence	4
1.5	Les grandes phases du projet	5
A	Glossaire : les termes du schéma en langage courant	7
A.1	Modéliser : le neurone, la synapse, le réseau	7
A.2	Accélérer : les termes du calcul	8
A.3	Mesurer et généraliser : les termes de la preuve et du livrable	9
B	Notations mathématiques employées dans le schéma	11

Reformulation du sujet

1.1 Ce que demande le sujet

L'intitulé *Optimisation de modèles neuronaux à oscillateurs couplés* réunit deux exigences qui tirent dans des directions opposées.

D'un côté, une exigence de **fidélité biophysique**. Le neurone n'est pas ici une simple unité de calcul : il est décrit par le formalisme de Hodgkin-Huxley, c'est-à-dire par un système d'équations différentielles non linéaires qui reproduit le mécanisme physique réel du potentiel d'action. Chaque neurone se comporte comme un oscillateur, et ces oscillateurs sont *couplés* entre eux par des synapses chimiques à conductance, elles-mêmes régies par leur propre dynamique.

De l'autre, une exigence de **vitesse**. Le sujet ne se contente pas de deux ou trois neurones : il demande de monter en taille jusqu'à des réseaux de l'ordre de 10^4 neurones. À cette échelle, l'intégration numérique naïve sur processeur devient hors de portée, et l'accélération matérielle (GPU) n'est plus une option de confort mais la condition de faisabilité de l'expérience.

Reformulé en une phrase, le sujet revient donc à **construire un réseau de neurones biophysiques couplés, le simuler fidèlement, le calculer vite, et prouver que la vitesse gagnée ne s'est pas payée en fidélité perdue**. La difficulté n'est ni d'écrire un simulateur, ni d'écrire du code GPU : elle est de tenir les deux bouts en même temps, et de le démontrer par la mesure plutôt que de l'affirmer.

C'est cette tension qui structure la carte conceptuelle présentée figure 1.1.

1.2 La carte conceptuelle




FIGURE 1.1 – Reformulation du sujet sous forme de carte conceptuelle : un objet d'étude central, quatre dimensions de travail, et une boucle d'itération qui les relie.

1.3 Lecture du schéma

1.3.1 Le noyau : ce que l'on étudie

Au centre du schéma figure l'objet d'étude, formulé sans jargon : *un réseau de neurones biophysiques couplés, simulé fidèlement et calculé vite, jusqu'à grande échelle*. Ce noyau est volontairement descriptif et non interrogatif : il nomme ce que le projet manipule, pas ce qu'il cherche à trancher.

Juste en dessous, une étiquette rappelle l'axe de tension du sujet : **vitesse $\rightleftharpoons$ fidélité biophysique**. Les deux termes ne sont pas des objectifs indépendants que l'on pourrait maximiser séparément ; ils s'échangent l'un contre l'autre. Simplifier le modèle, agrandir le pas de temps ou descendre en précision numérique fait gagner du temps de calcul et perdre de la fidélité. Toute décision technique du projet se situe quelque part sur cet axe, et c'est parce que cet arbitrage existe que les quatre dimensions du schéma sont nécessaires.

1.3.2 Les quatre dimensions

Autour du noyau, le sujet se décline en quatre dimensions, chacune répondant à une question différente.

1. Modéliser — *quoi* ? Cette dimension définit le substrat biophysique à reproduire. Elle descend du neurone isolé (Hodgkin-Huxley, 1952 : un état à quatre variables (V, m, h, n) , quatre équations différentielles raides couplées, un pas de temps contraint) à la synapse (modèle cinétique de Destexhe, 1994, excitatrice ou inhibitrice), puis au connectome, c'est-à-dire au graphe des connexions, dont la structure de petit monde et la matrice creuse conditionnent tout le coût de calcul. Le dernier point est le plus important : ce que l'on doit préserver n'est pas une courbe, ce sont des *régimes* — potentiels d'action, bouffées, synchronisation. C'est la signature qualitative du réseau qui fait office de critère de fidélité.

2. Accélérer — *comment* ? Cette dimension rassemble les stratégies de calcul à confronter. Elle commence par ce qui n'est pas du GPU : une référence CPU exacte, à pas adaptatif, qui sert de vérité terrain. Sans cette référence, aucune accélération n'est vérifiable. Viennent ensuite le portage GPU, plusieurs leviers d'optimisation (vectorisation, produit matrice creuse-vecteur, pas fixe, gestion de la mémoire vidéo) et, à nouveau, un compromis explicite : la précision numérique s'échange contre le débit.

3. Mesurer — *combien* ? Cette dimension est la preuve expérimentale à produire, et elle porte les critères d'acceptation du projet. Trois familles d'indicateurs : le gain (l'accélération S en fonction de la taille du réseau), le passage à l'échelle (coût par pas de temps, mémoire occupée, seuil de taille à partir duquel le GPU devient rentable), et la non-dérive (l'écart maximal entre trace GPU et trace CPU, mais aussi la conservation des dates de décharge). Le protocole de mesure figure explicitement dans le schéma, parce qu'une mesure non reproductible ne prouve rien.

4. Généraliser — *pour quoi* ? Cette dimension définit le livrable final : non pas un programme qui tourne une fois, mais un socle réutilisable. Les quatre briques — neurone, synapse, connectome, solveur — doivent être interchangeable, de sorte que changer de modèle ou de topologie ne demande pas de réécrire le moteur de simulation. Elle inscrit enfin le projet dans ses débouchés : neurosciences computationnelles, bio-électronique, interfaces cerveau-machine.

1.3.3 L'anneau : une démarche itérative, pas linéaire

Les quatre dimensions sont reliées par une boucle orientée, et c'est le point le plus important de la lecture du schéma. Modéliser produit des équations, un graphe et un jeu de tests, qui alimentent l'accélération ; accélérer produit des exécutions comparées, CPU contre GPU, qui alimentent la mesure ; mesurer produit des temps et des traces de potentiel, qui alimentent la généralisation.

La quatrième flèche, tracée en pointillés, ferme la boucle et revient sur la modélisation : changer de modèle de neurone, de topologie de réseau ou d'échelle relance le cycle complet. Elle est en pointillés parce qu'elle est facultative dans une itération donnée, mais elle est la raison d'être de la dimension *généraliser* : si le socle est correctement découplé, ce retour coûte peu ; s'il ne l'est pas, il coûte une réécriture.

1.4 Ce que le schéma met en évidence

Trois enseignements se dégagent de cette mise en forme.

Le verrou n'est pas le GPU, c'est l'arbitrage. Porter un calcul sur carte graphique est un problème d'ingénierie connu. Le vrai verrou du sujet est de savoir *jusqu'où* on peut simplifier le modèle, agrandir le pas de temps ou réduire la précision numérique avant que le réseau ne cesse de se comporter comme un réseau de neurones. Cette frontière ne se devine pas : elle se mesure.

La mesure est un livrable, pas un sous-produit. Dans beaucoup de projets d'optimisation, le banc d'essai est bricolé à la fin. Ici il occupe un quart du schéma, au même rang que le modèle lui-même, parce qu'il est le seul moyen de démontrer que la contrainte de fidélité a été tenue. La référence CPU exacte est à ce titre un livrable critique, et non une étape préliminaire jetable.

La généricité conditionne la valeur du travail. Un simulateur monolithique réglé pour Hodgkin-Huxley et Watts-Strogatz répondrait au sujet une fois, puis mourrait avec lui. Le découpage en briques interchangeables est ce qui transforme le projet en socle réutilisable, et c'est aussi ce qui rend la boucle d'itération abordable dans le temps imparti.

1.5 Les grandes phases du projet

Le projet se déroule sur deux semestres, pour un volume total de 132 heures : 32 heures en semestre 7, consacrées au cadrage, à l'état de l'art et à l'analyse fonctionnelle, puis 100 heures en semestre 8, consacrées à la réalisation, à l'accélération GPU et aux campagnes de mesure. Le jalon qui sépare les deux est la disponibilité d'un étalon CPU validé : tant qu'il n'existe pas, aucune mesure d'accélération n'a de sens.

Le tableau 1.1 récapitule ces phases et les relie aux dimensions du schéma.

TABLE 1.1 : Grandes phases du projet et correspondance avec les dimensions du schéma.

Ph.	Intitulé	Période	Contenu et livrables	Dimension
1	Cadrage et reformulation	S7 — sept.	Reformulation du sujet et carte conceptuelle (L1), note de clarification : objectifs, périmètre, parties prenantes, risques (L2).	Cadrage général
2	État de l'art et verrous	S7 — oct.	Synthèse bibliographique comparative et identification des verrous techniques (L3).	Modéliser, Accélérer
3	Analyse fonctionnelle	S7 — oct.	Bête à cornes, pieuvre, hiérarchisation des fonctions (L4) ; décomposition FAST et schéma synoptique du système (L5).	Généraliser
4	Étalon CPU et socle logiciel	S7 → S8	Implémentation Hodgkin-Huxley avec couplage synaptique, générateurs de connectomes, solveur de référence exact et tests de validation biophysique.	Modéliser
5	Accélération et portage GPU	S8	Version vectorisée, portage tensoriel puis noyaux dédiés, propagation synaptique creuse, optimisation de la mémoire.	Accélérer
6	Campagne de mesures	S8	Banc d'essai reproductible, courbes d'accélération et de passage à l'échelle, contrôle de non-dérive par rapport à l'étalon CPU.	Mesurer
7	Généralisation et livraison	S8	Consolidation en bibliothèque modulaire documentée, tests de non-régression, notebooks de démonstration, soutenance finale.	Généraliser

Les phases 4 à 7 ne s'enchaînent pas strictement : elles suivent la boucle du schéma. Une campagne

de mesure qui révèle une dérive renvoie à la modélisation ou au portage, et le cycle recommence sur une taille de réseau ou une topologie différente.

Glossaire : les termes du schéma en langage courant

Cette annexe reprend, dans l'ordre des quatre dimensions, chaque terme technique employé dans le schéma et dans le texte qui le commente. Les définitions y sont volontairement non spécialisées : elles visent à rendre la carte conceptuelle lisible par un lecteur qui n'est ni neuroscientifique ni spécialiste du calcul parallèle.

A.1 Modéliser : le neurone, la synapse, le réseau

Terme	En langage courant
Neurone biophysique	Une description d'un neurone qui imite le fonctionnement physique réel de sa membrane (des ions qui entrent et sortent), et non une simple fonction mathématique d'entrée-sortie comme dans un réseau de neurones artificiel.
Oscillateur couplé	Un système qui produit spontanément un signal qui se répète, et dont le rythme est influencé par celui de ses voisins. Un neurone qui décharge régulièrement en est un ; des milliers de neurones connectés forment un ensemble d'oscillateurs couplés.
Potentiel de membrane	La tension électrique entre l'intérieur et l'extérieur du neurone, exprimée en millivolts. C'est la grandeur que l'on observe et que l'on trace au cours du temps : c'est le « signal » du neurone.
Potentiel d'action (ou décharge, <i>spike</i>)	La brusque impulsion de tension, très brève, par laquelle un neurone transmet une information. C'est l'événement élémentaire du langage neuronal.
Bouffée (<i>burst</i>)	Une salve de plusieurs potentiels d'action rapprochés, suivie d'un silence. C'est un régime de fonctionnement courant et très sensible aux détails du modèle.
Synchronisation	Le fait que plusieurs neurones finissent par décharger ensemble, en rythme. C'est une propriété collective du réseau : elle n'existe pas au niveau d'un neurone isolé, et elle disparaît si la simulation est imprécise.
Modèle de Hodgkin-Huxley (1952)	Le modèle historique de référence du potentiel d'action, qui a valu le prix Nobel à ses auteurs. Il décrit le neurone par quatre grandeurs qui évoluent ensemble : la tension de membrane et trois « vannes » ioniques.
Variables de porte	Les trois grandeurs, comprises entre 0 et 1, qui représentent la proportion de canaux ioniques ouverts. On peut les voir comme le degré d'ouverture de vannes qui laissent passer le courant.
Équation différentielle	Une équation qui ne donne pas directement la valeur d'une grandeur, mais sa <i>vitesse de variation</i> . Pour connaître l'évolution, il faut la « dérouler » pas à pas dans le temps.
Système raide (<i>stiff</i>)	Un système où coexistent des phénomènes très rapides et très lents. Il oblige à avancer par très petits pas de temps, même pendant les périodes calmes, sous peine de résultats aberrants : c'est la principale source du coût de calcul.

Terme	En langage courant
Pas de temps	L'intervalle de temps dont on avance à chaque étape du calcul. Plus il est petit, plus la simulation est fidèle et plus elle est lente.
Synapse chimique	La connexion entre deux neurones : le neurone émetteur libère un messenger chimique qui ouvre des canaux chez le neurone récepteur, ce qui y crée un courant.
Modèle cinétique (Destexhe, 1994)	Le modèle de synapse retenu dans le projet. Il ne se contente pas d'additionner une impulsion : il suit dans le temps la proportion de récepteurs activés, ce qui donne une réponse progressive et réaliste.
Synapse excitatrice / inhibitrice	Une synapse excitatrice rapproche le neurone récepteur du seuil de décharge ; une synapse inhibitrice l'en éloigne. L'équilibre entre les deux détermine le régime du réseau.
Conductance	La facilité avec laquelle le courant passe à travers la membrane. C'est l'inverse d'une résistance ; c'est elle que la synapse fait varier.
Connectome	La carte des connexions du réseau : qui est relié à qui, et avec quelle force.
Graphe	La représentation mathématique de cette carte : des points (les neurones) reliés par des flèches (les synapses).
Matrice d'adjacence	Le tableau de nombres qui code le graphe : la case en ligne i , colonne j vaut zéro s'il n'y a pas de connexion, et la force du lien sinon.
Matrice creuse (<i>sparse</i>)	Une matrice dont l'immense majorité des cases valent zéro, comme c'est le cas dans un cerveau. On ne stocke alors que les cases non nulles, ce qui économise énormément de mémoire et de calcul.
Réseau petit monde (Watts-Strogatz)	Un réseau très majoritairement composé de connexions locales, auxquelles s'ajoutent quelques raccourcis à longue distance. Ces quelques raccourcis suffisent à relier tout le réseau en très peu d'étapes : c'est l'effet « six degrés de séparation », et c'est une structure observée dans les tissus nerveux réels.

A.2 Accélérer : les termes du calcul

Terme	En langage courant
CPU	Le processeur central de l'ordinateur. Peu d'unités de calcul, mais chacune très rapide et très polyvalente : idéal pour mener un calcul compliqué à la fois.
GPU	La carte graphique. Des milliers d'unités de calcul beaucoup plus simples, qui ne sont efficaces que s'ils font tous la même opération en même temps sur des données différentes. C'est exactement le cas d'un réseau où tous les neurones obéissent aux mêmes équations.
Intégration numérique	L'action de « dérouler » les équations différentielles pas à pas pour obtenir l'évolution dans le temps. C'est là que se concentre l'essentiel du coût de calcul.
Solveur	Le programme qui réalise cette intégration. Le projet en compare plusieurs.
Pas adaptatif	Une stratégie où le solveur choisit lui-même la taille de chaque pas : petit quand le signal varie vite, grand quand il est calme. Très précis, mais difficile à paralléliser, car chaque neurone voudrait son propre rythme.
Pas fixe	La stratégie inverse : le même pas pour tout le monde, tout le temps. Moins fin, mais tous les neurones avancent ensemble, ce qui convient au GPU.
Vérité terrain (ou référence, étalon)	Le résultat considéré comme correct, produit par la méthode la plus sûre et la plus lente. Toutes les versions rapides sont comparées à lui.
Parallélisme SIMT	Le mode de fonctionnement du GPU : une même instruction exécutée simultanément par de nombreux fils de calcul, chacun sur ses propres données. Ici, typiquement un fil par neurone.

Terme	En langage courant
Fil (<i>thread</i>)	La plus petite unité de calcul qui s'exécute indépendamment. Un GPU en fait tourner des dizaines de milliers à la fois.
Noyau CUDA (<i>kernel</i>)	Un petit programme écrit spécifiquement pour s'exécuter sur la carte graphique. CUDA est la technologie de programmation des cartes NVIDIA.
PyTorch, CuPy	Deux bibliothèques Python qui permettent de faire calculer une carte graphique sans écrire soi-même de code CUDA, en manipulant directement des tableaux de nombres.
Vectorisation	Remplacer une boucle qui traite les neurones un par un par une seule opération appliquée à tout le tableau d'un coup. C'est le premier gain de performance, et il vaut déjà sur CPU.
Produit matrice creuse-vecteur (SpMV)	L'opération qui calcule, en une fois, le courant reçu par tous les neurones à partir de l'activité de leurs voisins. C'est l'opération la plus fréquente de la simulation, donc la première à optimiser.
VRAM	La mémoire embarquée sur la carte graphique. Elle est rapide mais limitée : c'est souvent elle qui fixe la taille maximale du réseau simulable.
Transferts mémoire	Les copies de données entre la mémoire de l'ordinateur et celle de la carte graphique. Elles sont lentes ; un portage naïf passe plus de temps à transférer qu'à calculer.
Occupation	La proportion de la capacité de calcul du GPU réellement utilisée. Une occupation faible signifie que la carte attend au lieu de travailler.
float32 / float64	Deux façons de représenter un nombre à virgule : sur 32 bits (environ 7 chiffres significatifs) ou sur 64 bits (environ 16). La première est deux fois plus légère et nettement plus rapide sur GPU, mais accumule plus d'erreurs d'arrondi.
Débit	La quantité de calcul utile effectuée par seconde. C'est ce que l'on cherche à maximiser, et ce que l'on échange contre de la précision.

A.3 Mesurer et généraliser : les termes de la preuve et du livrable

Terme	En langage courant
Accélération (<i>speedup</i>)	Le rapport entre le temps mis par le CPU et celui mis par le GPU pour le même calcul. Une accélération de 20 signifie vingt fois plus rapide.
Passage à l'échelle (scalabilité)	La façon dont le temps de calcul et la mémoire augmentent quand le réseau grandit. Un bon passage à l'échelle, ce n'est pas seulement être rapide sur un petit réseau : c'est ne pas s'effondrer sur un grand.
Seuil de bascule	La taille de réseau à partir de laquelle le GPU devient plus rentable que le CPU. En dessous, les coûts de transfert et de lancement dominant et le GPU peut être plus lent.
Non-dérive	Le fait que la version accélérée donne le même résultat que la référence. On la contrôle de deux façons : l'écart maximal entre les deux courbes de tension, et la conservation des instants de décharge.
Écart maximal (norme infinie)	Le plus grand écart observé entre deux courbes sur toute la durée de la simulation. C'est un critère sévère : il suffit d'un seul instant de désaccord pour le faire grimper.
Tolérance	Le seuil d'écart en dessous duquel deux résultats sont déclarés équivalents. Il doit être fixé avant les mesures, pas après.
Conditions initiales	L'état du réseau au début de la simulation. Deux simulations ne sont comparables que si elles partent exactement du même état.

Terme	En langage courant
Reproductibilité	La garantie qu'une même expérience, relancée, redonne le même résultat. Elle impose de fixer les tirages aléatoires et de consigner le matériel et les versions de logiciels utilisés.
Protocole de mesure	L'ensemble des règles fixées à l'avance : durée simulée, tailles testées, nombre de répétitions, ce que l'on chronomètre exactement. Sans lui, deux mesures ne se comparent pas.
Architecture modulaire	Un logiciel découpé en briques indépendantes qui s'emboîtent par des interfaces stables. Ici : le neurone, la synapse, le connectome et le solveur.
Moteur de simulation	La partie du code qui fait avancer le temps. L'objectif de modularité est de pouvoir changer de modèle de neurone ou de topologie sans jamais y toucher.
Test de non-régression	Un test automatique qui vérifie qu'une modification du code n'a pas cassé un comportement qui fonctionnait auparavant. C'est le filet de sécurité d'un socle destiné à être réutilisé.
Notebook	Un document exécutable mêlant code, courbes et explications, qui permet de rejouer une démonstration sans avoir à lire tout le code source.
Neurosciences computationnelles	La discipline qui étudie le cerveau en le simulant, pour tester des hypothèses que l'expérience biologique ne permet pas d'isoler.
Bio-électronique	La conception de circuits électroniques qui dialoguent avec du vivant, voire qui en imitent le fonctionnement.
Interface cerveau-machine	Un dispositif qui lit l'activité neuronale et la traduit en commande. Ces systèmes doivent souvent simuler ou décoder en temps réel, d'où leur intérêt direct pour un travail d'accélération.

Notations mathématiques employées dans le schéma

Notation	Se lit	Signification
$\bar{V}$	Tension de membrane	Le signal électrique du neurone, en millivolts. C'est la grandeur observée.
(V, m, h, n)	État d'un neurone	Les quatre nombres qui décrivent entièrement un neurone à un instant donné : sa tension et ses trois variables de porte.
$V(t)$	Tension au cours du temps	La courbe de tension sur toute la durée de la simulation : la « trace » que l'on compare entre CPU et GPU.
$dt \leq 0,05 \text{ ms}$	Pas de temps	Le pas d'intégration doit rester inférieur à cinq centièmes de milliseconde pour que le calcul reste stable.
Δt	Pas de simulation	Le même pas, vu du côté du coût : on mesure le temps de calcul dépensé par pas.
I_{syn}	Courant synaptique	Le courant qu'un neurone reçoit de tous ceux qui lui sont connectés.
g	Conductance synaptique	La force de la connexion : elle règle l'amplitude du courant transmis.
s_{ij}	Variable synaptique	La proportion de récepteurs activés sur la connexion allant du neurone j vers le neurone i ; elle vaut entre 0 et 1.
E	Potentiel de réversion	La tension vers laquelle la synapse tire le neurone. Elle décide du caractère excitateur ou inhibiteur de la connexion.
W	Matrice de connectivité	Le tableau des poids de connexion du réseau ; il est creux, c'est-à-dire presque entièrement nul.
N	Taille du réseau	Le nombre de neurones simulés.
$N : 10 \rightarrow 10^4$	Plage de tailles	Le projet balaie des réseaux de dix neurones jusqu'à dix mille, pour observer l'évolution des performances.
$T_{\text{CPU}}, T_{\text{GPU}}$	Temps d'exécution	La durée mesurée d'une même simulation sur processeur et sur carte graphique.
$S = T_{\text{CPU}}/T_{\text{GPU}}$	Facteur d'accélération	Combien de fois le GPU va plus vite que le CPU pour un calcul identique.
$\ V_{\text{GPU}} - V_{\text{CPU}}\ _{\infty}$	Écart maximal	Le plus grand écart de tension observé entre les deux versions sur l'ensemble de la simulation.
ε	Tolérance	Le seuil d'écart accepté, fixé à l'avance, en dessous duquel les deux résultats sont jugés équivalents.
$\rightleftharpoons$	Compromis	Les deux flèches opposées signalent un arbitrage : gagner sur un terme se paie sur l'autre.